

Rozdział 3. Kwantowe uczenie maszynowe i hybrydowe kwantowe sieci neuronowe

Celem niniejszego rozdziału jest wprowadzenie aparatu pojęciowego i metodologicznego potrzebnego do zrozumienia części metodologicznej oraz wynikowej pracy, w której hybrydowe kwantowe sieci neuronowe są wykorzystywane do klasyfikacji ryzyka finansowo-sprawozdawczego spółek publicznych. Rozdział nie ma charakteru wykładu z informatyki kwantowej służy jedynie wyjaśnieniu tych elementów obliczeń kwantowych, które są bezpośrednio wymagane do zaprojektowania modelu działającego na małowymiarowych wektorach cech liczbowych zakodowanych w postaci danych tabelarycznych. Rozdział składa się z trzech części, które przedstawiają kolejno podstawowe pojęcia kwantowego uczenia maszynowego, problematykę kodowania danych klasycznych do kubitów oraz ograniczenia praktyczne obwodów kwantowych. W całym rozdziale przyjęto ostrożne podejście: kwantowe sieci neuronowe (ang. Quantum Neural Networks, QNN) są traktowane jako eksperymentalna rodzina modeli, którą należy rzetelnie porównać z klasycznymi metodami uczenia maszynowego. Nie są to zatem narzędzia z góry gwarantujące przewagę nad modelami klasycznymi.

3.1. Podstawy kwantowego uczenia maszynowego

Kwantowe uczenie maszynowe (ang. Quantum Machine Learning, QML) jest szeroką rodziną metod łączących idee uczenia maszynowego z obliczeniami kwantowymi¹. W literaturze termin ten bywa używany w odniesieniu do różnych klas podejść: od modeli uczących się na danych reprezentujących stany lub procesy kwantowe, przez koncepcje zakładające, że algorytmy kwantowe mogą przyspieszyć niektóre obliczenia znane z klasycznego uczenia maszynowego, aż po modele hybrydowe, w których klasyczne dane są kodowane do obwodu kwantowego i przetwarzane przez parametryzowane bramki. Należy w tym miejscu podkreślić, że QML nie zastępuje całej procedury analitycznej. Część kwantowa (obliczeniowa) współpracuje z klasycznym algorytmem wstępnego przetwarzania danych oraz optymalizacyjnym².

Podstawową jednostką informacji w modelu obliczeń kwantowych jest kubit. Klasyczny bit przyjmuje jedną z dwóch wartości: 0 albo 1. Kubit kwantowy jest opisywany jako wektor w dwuwymiarowej przestrzeni Hilberta, będący kombinacją liniową dwóch

¹ J. Biamonte i in., *Quantum machine learning*, „Nature” 2017, vol. 549, nr 7671, s. 195–202.

² M. Benedetti i in., *Parameterized quantum circuits as machine learning models*, „Quantum Science and Technology” 2019, vol. 4, nr 4, art. 043001.

stanów bazowych oznaczanych zwykle jako $|0\rangle$ i $|1\rangle$. Najprostszy zapis stanu pojedynczego kubit ma postać:

$$(3.1) \quad |\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \text{ gdzie } |\alpha|^2 + |\beta|^2 = 1.$$

Współczynniki α i β są zespolonymi amplitudami prawdopodobieństwa. Zgodnie z regułą Borna wartości $|\alpha|^2$ oraz $|\beta|^2$ określają prawdopodobieństwa uzyskania wyników odpowiednio 0 i 1 przy pomiarze w bazie obliczeniowej, natomiast warunek normalizacji zapewnia, że suma tych prawdopodobieństw wynosi zawsze jeden³. Dla pojedynczego kubit szczególnie użyteczną interpretację geometryczną daje sfera Blocha, czyli sfera jednostkowa służąca do reprezentacji czystych stanów dwupoziomowego układu kwantowego⁴. Po pominięciu globalnego czynnika fazowego ($e^{i\gamma}$), który nie wpływa na prawdopodobieństwa wyników pomiaru, każdy czysty stan pojedynczego kubit można zapisać w postaci⁵:

$$(3.2) \quad |\psi\rangle = \cos\frac{\theta}{2}|0\rangle + e^{i\varphi}\sin\frac{\theta}{2}|1\rangle, \text{ gdzie } 0 \leq \theta \leq \pi \text{ oraz } 0 \leq \varphi < 2\pi.$$

Parametry θ i φ mają interpretację współrzędnych sferycznych: θ określa kąt względem osi pionowej, natomiast φ jest kątem azymutalnym, odpowiadającym fazie względnej między stanami $|0\rangle$ i $|1\rangle$ ⁶. Stan $|0\rangle$ odpowiada biegunowi północnemu, stan $|1\rangle$ biegunowi południowemu, a pozostałe punkty powierzchni sfery reprezentują różne superpozycje stanów bazowych względem przyjętej bazy obliczeniowej⁷.

Takie ujęcie pozwala uniknąć potocznego stwierdzenia, że kubit „jest jednocześnie zerem i jedyką”. Precyzyjniej należy stwierdzić, że stan kubit jest wektorem w przestrzeni Hilberta, którego amplitudy i faza względna określają stan układu, a tym samym rozkłady prawdopodobieństwa wyników pomiarów wykonywanych w różnych bazach. W kontekście kwantowego uczenia maszynowego istotna jest nie sama geometryczna interpretacja pojęcia superpozycji, lecz możliwość przekształcenia stanu kwantowego kubit za pomocą operacji unitarnych (bramek kwantowych) oraz wykorzystanie operacji pomiaru w celu uzyskania klasycznej wielkości wykorzystywanej przez dalszą część modelu hybrydowego⁸.

³ M.A. Nielsen, I.L. Chuang, *Quantum Computation and Quantum Information*, 10th Anniversary Edition, Cambridge University Press, Cambridge 2010, s. 13–14.

⁴ T.G. Wong, *Introduction to Classical and Quantum Computing*, Rooted Grove, Omaha 2022, s. 74-76, 91-94.


⁵ M.A. Nielsen, I.L. Chuang: op. cit. s. 15–16; T.G. Wong: op. cit. s. 91–92.

⁶ T.G. Wong: op. cit. s. 92-94.

⁷ T.G. Wong: op. cit. s. 95-97.

⁸ S. Zając, J.L. Cybulski, T. Kulpa, *Kwantowe algorytmy hybrydowe jako modele uczenia maszynowego*, [w:] *Sztuczna inteligencja w przedsiębiorstwach i gospodarce (AI Spring 2024)*, red. T. Doligalski, D. Kaszyński, Oficyna Wydawnicza SGH, Warszawa 2025, s. 164, 168–174.

Rysunek 3.1. Reprezentacja stanu pojedynczego kubit na sferze Blocha



Źródło: opracowanie własne na podstawie literatury przedmiotu wskazanej w rozdziale; wizualizacja przygotowana z wykorzystaniem narzędzia generatywnej sztucznej inteligencji GPT Image / ChatGPT, OpenAI.

Stan układu złożonego z n kubitów może zostać opisany w przestrzeni Hilberta o wymiarze 2^n . Jeżeli amplitudy prawdopodobieństwa (α_k) zostaną przypisane stanom bazowym ($|k\rangle$), to stan rejestru kwantowego można zapisać w postaci⁹:

$$(3.3) \quad |\psi\rangle = \sum_{k=0}^{2^n-1} \alpha_k |k\rangle, \quad \sum_{k=0}^{2^n-1} |\alpha_k|^2 = 1.$$

W tym miejscu należy podkreślić, że wykładniczy wymiar przestrzeni stanu nie jest równoważny z potocznym stwierdzeniem, że „komputer kwantowy sprawdza wszystkie możliwości naraz”. Pojedynczy pomiar zwraca jeden wynik klasyczny zgodnie z rozkładem prawdopodobieństwa wyznaczonym przez amplitudy¹⁰. Informacja o stanie kwantowym jest dostępna jedynie pośrednio: przez statystyki wielu uruchomień obwodu kwantowego można estymować rozkłady wyników pomiaru lub wartości oczekiwane wybranych obserwabli¹¹. W modelu kwantowego uczenia maszynowego obwód zależny od danych wejściowych x oraz

⁹ M.A. Nielsen, I.L. Chuang: op. cit. s. 16-17.

¹⁰ E.G. Rieffel, W.H. Polak, *Quantum Computing. A Gentle Introduction*, The MIT Press, Cambridge–London 2011, s. 55–60, 326-327.

¹¹ M. Schuld, F. Petruccione, *Supervised Learning with Quantum Computers*, Springer, Cham 2018, s. 84-91.

od parametrów uczonych θ przekształca stan początkowy w stan końcowy $|\psi(x, \theta)\rangle$, dla którego można estymować wartość oczekiwaną obserwabli $\langle O \rangle$ ¹².

$$(3.4) \quad f(x; \theta) = \langle \psi(x; \theta) | O | \psi(x; \theta) \rangle.$$

Wartość oczekiwana obserwabli może następnie zostać potraktowana jako ciągła zmienna wyjściowa modelu i przekształcona w decyzję klasyfikacyjną zależnie od przyjętych reguł decyzyjnych, co zostało szerzej omówione w rozdziale metodologicznym.

Najbardziej rozpowszechnionym modelem prezentacji algorytmów kwantowych jest model obwodowy, w którym występują bramki realizujące przetwarzanie informacji. Wyróżnia się bramki działające na jednym kubicie oraz bramki dwu i więcej kubitowe. Bramki jednokubitowe zostały zdefiniowane jako bramki realizujące dowolną operację opisaną operatorem unitarnym U działającym w przestrzeni Hilberta o wymiarze dwa¹³. Dla kwantowego uczenia maszynowego szczególnie ważne są bramki rotacyjne, ponieważ ich kąty mogą kodować klasyczne cechy wejściowe albo stanowić parametry uczone w trakcie treningu. Przykładem takiej bramki jest bramka rotacji wokół osi y :

$$(3.5) \quad R_y(\varphi) = \begin{pmatrix} \cos\left(\frac{\varphi}{2}\right) & -\sin\left(\frac{\varphi}{2}\right) \\ \sin\left(\frac{\varphi}{2}\right) & \cos\left(\frac{\varphi}{2}\right) \end{pmatrix}$$

Bramka $R_y(\varphi)$ realizuje obrót stanu kubitów o kąt φ wokół osi y sfery Blocha. Za pomocą wzoru (3.5) można wyjaśnić dwie kluczowe role bramek rotacyjnych. Jeżeli kąt φ wyznaczony jest na podstawie klasycznej cechy wejściowej, to bramka $R_y(\varphi)$ odpowiada za kodowanie danych do stanu kwantowego (angle encoding)¹⁴. W ten sposób klasyczny wektor cech może zostać przekształcony w stan układu kubitów. Kąt φ może również zostać potraktowany jako parametr θ aktualizowany w trakcie uczenia w warstwie wariacyjnej modelu¹⁵. Więcej przykładów bramek i operatorów kwantowych przedstawia tabela 3.1.

¹² M. Schuld, F. Petruccione: op. cit. s. 230

¹³ M. Sawerwain, J. Wiśniewska, *Informatyka kwantowa. Wybrane obwody i algorytmy*, Wydawnictwo Naukowe PWN, Warszawa 2015, s. 107-108.

¹⁴ E. F. Combarro, S. González-Castillo, *A Practical Guide to Quantum Machine Learning and Quantum Optimization. Hands-on Approach to Modern Quantum Algorithms*, Packt Publishing, Birmingham–Mumbai 2023, s. 368-369.

¹⁵ Tamże, s. 393-398.

Tabela 3.1. Wybrane operacje kwantowe stosowane w modelach kwantowego uczenia maszynowego

Bramka / operator	Zapis matematyczny	Cechy charakterystyczne / zastosowanie
H - bramka Hadamarda	$\frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$	Superpozycja stanów bazowych; przygotowanie cech wejściowych.
$R_x(\varphi)$ - rotacja wokół osi x	$\begin{pmatrix} \cos\left(\frac{\varphi}{2}\right) & -i \sin\left(\frac{\varphi}{2}\right) \\ -i \sin\left(\frac{\varphi}{2}\right) & \cos\left(\frac{\varphi}{2}\right) \end{pmatrix}$	Rotacja wokół osi x ; parametryzacja obwodu.
$R_y(\varphi)$ - rotacja wokół osi y	$\begin{pmatrix} \cos\left(\frac{\varphi}{2}\right) & -\sin\left(\frac{\varphi}{2}\right) \\ \sin\left(\frac{\varphi}{2}\right) & \cos\left(\frac{\varphi}{2}\right) \end{pmatrix}$	Rotacja wokół osi y ; stosowana w <i>angle encoding</i> oraz w warstwie wariacyjnej.
$R_z(\varphi)$ - rotacja wokół osi z	$\begin{pmatrix} e^{-i\varphi/2} & 0 \\ 0 & e^{i\varphi/2} \end{pmatrix}$	Rotacja fazowa; kodowanie informacji w fazie.
Z - obserwabla Pauli-Z	$\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$	Obserwabla pomiarowa; odczyt wartości oczekiwanej.
$U(\theta, \phi, \lambda)$ - ogólna bramka jednokubitowa	$\begin{pmatrix} \cos\left(\frac{\theta}{2}\right) & -e^{i\lambda}\sin\left(\frac{\theta}{2}\right) \\ e^{i\phi}\sin\left(\frac{\theta}{2}\right) & e^{i(\phi+\lambda)}\cos\left(\frac{\theta}{2}\right) \end{pmatrix}$	Ogólna operacja jednokubitowa; dowolna operacja unitarna z dokładnością do fazy globalnej.
CNOT/ CX - kontrolowana negacja	$\text{CNOT} a, b\rangle = a, a \oplus b\rangle$	Splątanie kwantowe kubitów; zależności między kubitami i zakodowanymi cechami.
CZ – kontrolowana faza Z	$\text{CZ} a, b\rangle = (-1)^{ab} a, b\rangle$	Splątanie fazowe; modelowanie interakcji fazowych.

Źródło: opracowanie własne na podstawie: E. F. Combarro, S. González-Castillo, *A Practical Guide to Quantum Machine Learning and Quantum Optimization. Hands-on Approach to Modern Quantum Algorithms*, Packt Publishing, Birmingham–Mumbai 2023, s. 16–22, 28–35.

Parametryzowany obwód kwantowy (ang. Parameterized Quantum Circuit, PQC) można rozumieć jako obwód złożony z bramek stałych oraz bramek zależnych od parametrów¹⁶. Do pierwszej grupy należą przykładowo bramki splątujące, natomiast do drugiej można zaliczyć regulowane bramki rotacyjne. Obwody parametryzowane stanowią obecnie podstawowy element konstrukcyjny wielu współczesnych modeli kwantowego uczenia maszynowego.

Wyróżnia się również wariacyjne algorytmy kwantowe (ang. Variational Quantum Algorithms, VQA), które można określić jako klasę hybrydowych algorytmów kwantowo-klasycznych, w których parametryzowany obwód kwantowy jest wykonywany na komputerze kwantowym lub symulatorze, natomiast jego parametry są iteracyjnie dostrajane przez klasyczny optymalizator w celu minimalizacji określonej funkcji kosztu¹⁷. W modelu hybrydowym komputer klasyczny i komputer kwantowy nie wykonują więc tych samych zadań. Komputer klasyczny odpowiada za przygotowanie danych, zdefiniowanie funkcji celu, dobór i aktualizację parametrów oraz interpretację wyników. Zadanie komputera kwantowego ogranicza się do tej części obliczeń, która jest zapisana w postaci obwodu kwantowego, w szczególności przygotowanie stanu kwantowego, przeprowadzenie operacji kwantowych oraz zwrócenie wyników pomiaru np. wartość oczekiwana obserwabli. Taki podział jest zgodny między innymi z ogólnym schematem Qiskit patterns zaproponowanym przez IBM¹⁸, w którym problem jest najpierw mapowany na obwody i operatory kwantowe (algorytmy klasyczne), następnie wykonywany na docelowym urządzeniu kwantowym, a końcowy wynik również jest przetwarzany i interpretowany klasycznie. Cały proces działa w hybrydowej pętli, po obliczeniu funkcji straty i aktualizacji parametrów na komputerze klasycznym, wektor parametrów jest ponownie przekazywany do komputera kwantowego.

Pojęcie „kwantowa sieć neuronowa” (ang. Quantum Neural Network, QNN) nie ma w literaturze jednej, w pełni ustalonej definicji, z którą zgodziłyby się większość badaczy. Autor pracy przyjmuje praktyczne podejście oparte o modele obwodowe oraz odwołuje się do definicji przedstawionej w artykule „The power of quantum neural networks”, zgodnie z którą QNN można rozumieć jako podklasę wariacyjnych algorytmów kwantowych, obejmującą obwody kwantowe z parametryzowanymi operacjami bramkowymi¹⁹. W takim ujęciu dane

¹⁶ M. Benedetti i in., *Parameterized quantum circuits as machine learning models*, op. cit.

¹⁷ M. Cerezo i in., *Variational quantum algorithms*, „Nature Reviews Physics” 2021, vol. 3, s. 625–644.

¹⁸ IBM Quantum Documentation. *Development workflow / Qiskit patterns*, dostęp na dzień 26.05.2026r.

¹⁹ A. Abbas i in., *The power of quantum neural networks*, „Nature Computational Science” 2021, vol. 1, no. 6, s. 403–409, zwł. s. 404.

wejściowe są kodowane do stanu kwantowego, następnie przetwarzane przez model wariacyjny, a wynik pomiaru obwodu jest klasycznie przekształcany w etykietę lub predykcję modelu. QNN nie należy więc utożsamiać bezpośrednio z klasyczną siecią neuronową typu MLP; podobieństwo dotyczy przede wszystkim obecności parametrów uczonych i procedury treningu, natomiast sposób przetwarzania danych wynika z ewolucji stanu kwantowego, pomiaru oraz hybrydowej pętli optymalizacji klasyczno-kwantowej²⁰.

W tej części rozdziału należy jeszcze zdefiniować wariacyjny klasyfikator kwantowy (Variational Quantum Classifier, VQC), co będzie miało bezpośrednie znaczenie dla metodologii badania. VQC można zdefiniować jako klasyfikator uczenia nadzorowanego oparty na wariacyjnym, parametryzowanym, obwodzie kwantowym²¹. Wariacyjny klasyfikator kwantowy jest szczególnym przypadkiem wariacyjnego algorytmu kwantowego, stosowanym do klasyfikacji danych (model klasyfikacyjny / klasyfikator).

Podsumowując tę część rozdziału, kwantowe uczenie maszynowe należy traktować jako szeroką kategorię metod, w których techniki uczenia maszynowego są łączone z obliczeniami kwantowymi. Nie jest to jeden model, lecz rodzina podejść wykorzystujących zasoby kwantowe na różnych etapach uczenia. Takie ujęcie jest wystarczające dla dalszej części pracy, ponieważ pozwala oddzielić poziom ogólnej terminologii QML od konkretnej procedury eksperymentalnej. Część empiryczna pracy będzie koncentrowała się na budowie wariacyjnego klasyfikatora kwantowego (VQC), a kwantowe uczenie maszynowe (QML) pozostanie pojęciem nadrzędnym. Dalsza część rozdziału koncentruje się na praktycznym zastosowaniu VQC, w szczególności na kwantowej reprezentacji danych finansowych.

²⁰ M. Schuld, I. Sinayskiy, F. Petruccione, *The quest for a Quantum Neural Network*, „Quantum Information Processing” 2014, vol. 13, s. 2567–2586.

²¹ V. Havlíček i in., *Supervised learning with quantum-enhanced feature spaces*, „Nature” 2019, vol. 567, s. 209–212.

3.2. Kodowanie danych w hybrydowych kwantowych sieciach neuronowych

Jednym z bardziej istotnych wyzwań w implementacji modeli kwantowego uczenia maszynowego jest zaprojektowanie odpowiedniego schematu przygotowania danych wejściowych dopasowanego do sposobu przetwarzania danych w obwodzie kwantowym. Wektor cech wejściowych złożony z zestawu danych klasycznych (w tym przypadku będą to dane i wskaźniki finansowe) musi zostać przekształcony w parametry bramek lub amplitudy stanu kwantowego. Jak zostało wspomniane w poprzedniej części rozdziału, wstępne przetwarzanie danych, wliczając w to czyszczenie danych, uzupełnianie braków danych oraz wstępną redukcję liczby cech, realizowane jest na komputerze klasycznym przy pomocy metod i narzędzi znanych z klasycznej eksploracji danych. Dopiero po wstępnej transformacji danych następuje etap kodowania danych (ang. quantum encoding) do postaci zgodnej z założeniami i specyfikacją techniczną obwodu kwantowego.

Odwzorowanie klasycznego wektora cech $\mathbf{x}$ do stanu kwantowego $|\psi(\mathbf{x})\rangle$ za pomocą operatora $U_{\text{enc}}(\mathbf{x})$ nazywane jest mapą cech (ang. feature map). Uproszczony zapis kodowania danych przedstawia się następująco²²:

$$(3.6) \quad \varphi: \mathbf{x} \mapsto |\psi(\mathbf{x})\rangle = U_{\text{enc}}(\mathbf{x})|0\rangle^{\otimes n}.$$

Operator $U_{\text{enc}}(\mathbf{x})$ oznacza transformację unitarną realizowaną przez obwód kodujący dane. Jego konstrukcja zależy od wybranej metody kodowania, może zawierać bramki rotacyjne, przygotowanie stanu bazowego albo bardziej złożone procedury przygotowania amplitud. Schuld, Sweke i Meyer pokazują, że sposób kodowania danych wpływa na ekspresyjną moc wariacyjnych modeli kwantowych. W szczególności dobór bramek kodujących oraz liczba powtórzeń kodowania wpływają na zbiór częstotliwości dostępny modelowi w rozwinięciu Fouriera, a tym samym na klasę funkcji, które model może aproksymować²³. Z tej przyczyny w opisie kwantowej sieci neuronowej konieczne jest nie tylko wskazanie wektora cech, lecz także określenie sposobu jego odwzorowania na parametry obwodu.

W literaturze przedmiotu wyróżnia się różne metody kodowania danych, w tym kodowanie w bazie obliczeniowej (ang. basis encoding), kodowanie w kątach (ang. angle encoding) oraz kodowanie w amplitudach (ang. amplitude encoding)²⁴. Różnią się one

²² V. Havlíček i in., *Supervised learning with quantum-enhanced feature spaces*, op. cit.

²³ M. Schuld, R. Sweke, J.J. Meyer, *The effect of data encoding on the expressive power of variational quantum-machine-learning models*, „Physical Review A” 2021, vol. 103, 032430.

²⁴ M. Rath, H. Date, *Quantum data encoding: a comparative analysis of classical-to-quantum mapping techniques and their impact on machine learning accuracy*, „EPJ Quantum Technology” 2024, vol. 11, art. 72.

sposobem umieszczania klasycznych danych wejściowych w stanie kwantowym. Wybór metody kodowania powinien być dopasowany do charakteru, wymiarowości i skali danych wejściowych²⁵, a nie tylko do atrakcyjności formalnej danego rozwiązania.

Kodowanie w bazie obliczeniowej polega na bezpośrednim przypisaniu klasycznego ciągu bitów do stanu bazowego rejestru kubitów. Oznacza to, że każdy bit informacji klasycznej jest reprezentowany przez odpowiadający mu stan kubitów, np. wektor binarny $(1,0,1)$ może zostać zapisany jako stan $|101\rangle$. Metoda ta jest intuicyjna, w literaturze wskazuje się jednak, że w przypadku liczb rzeczywistych konieczne jest wcześniejsze przyjęcie określonej reprezentacji binarnej, co może wiązać się z utratą precyzji zapisu. Z tego względu kodowanie w bazie obliczeniowej jest szczególnie naturalne dla cech binarnych lub kategorii zakodowanych zero-jedynkowo. W przypadku ciągłych danych finansowych, takich jak ceny, trendy czy wskaźniki finansowe, metoda wymaga wcześniejszej dyskretyzacji, a zbyt mała precyzja takiej operacji może prowadzić do utraty części informacji²⁶.

Kodowanie w kątach jest prostszym sposobem reprezentowania danych rzeczywistych w obwodzie kwantowym, gdzie wartości cech są wykorzystywane jako parametry bramek rotacyjnych. W tym podejściu pojedyncza cecha x_i może sterować kątem obrotu kubitów, zazwyczaj przez bramkę obrotu R_Y albo R_X , dzięki czemu wartość liczbowa zostaje odwzorowana na położenie stanu na sferze Blocha. Dla bramki obrotu R_Y stan początkowy $|0\rangle$ może zostać przekształcony w superpozycję, której amplitudy zależą od wartości zakodowanego kąta²⁷. W praktyce oznacza to, że dane ciągłe nie muszą być najpierw zamieniane na ciąg bitów (co stanowi przewagę nad metodą kodowania w bazie obliczeniowej), lecz powinny zostać odpowiednio przeskalowane do zakresu interpretowanego jako kąt, na przykład do przedziału $[0,\pi]$ lub $[0,2\pi]$. Typowo jedna cecha jest kodowana na jednym kubicie, dlatego metoda ta jest mniej oszczędna pod względem liczby kubitów niż kodowanie amplitudowe. Ma ona jednak istotną zaletę implementacyjną polegającą na jej prostocie. Z tego powodu kodowanie w kątach jest często wykorzystywane w wariacyjnych obwodach kwantowych oraz modelach kwantowego uczenia maszynowego przeznaczonych dla współczesnych, ograniczonych sprzętowo komputerów kwantowych²⁸.

²⁵ IBM Quantum Learning, *Data encoding*, „Quantum Machine Learning”, IBM Quantum, dostęp: 27.05.2026.

²⁶ M. Schuld, F. Petruccione, *Supervised Learning with Quantum Computers*, op. cit., s. 109–110.

²⁷ Tamże, s. 186–188.

²⁸ IBM Quantum Learning, *Data encoding*, [w:] *Quantum Machine Learning*, IBM Quantum, dostęp: 27.05.2026.

Kodowanie w amplitudach przekształca wektor cech w amplitudy stanu kwantowego. Dla wektora cech $x = (x_1, \dots, x_d)$ idea polega na przygotowaniu stanu kwantowego:

$$(3.7) \quad |\psi_x\rangle = \sum_{i=1}^d x_i |i\rangle,$$

gdzie warunek $\sum_{i=1}^d |x_i|^2 = 1$ zapewnia poprawną normalizację amplitud. Główną przewagą tego podejścia polega na bardzo zwartej reprezentacji danych: rejestr złożony z n kubitów ma 2^n amplitud, dlatego do zapisania d -wymiarowego wektora potrzeba jedynie około $\lceil \log_2 d \rceil$ kubitów. Jeżeli liczba cech nie jest potęgą dwójki, wektor uzupełnia się zwykle dodatkowymi wartościami, na przykład zerami²⁹. W praktyce metoda ta może być jednak kosztowna, ponieważ wymaga przygotowania odpowiedniego stanu kwantowego, czyli zakodowania amplitud w rejestrze. Oznacza to, że oszczędność liczby kubitów nie zawsze przekłada się na pełną przewagę obliczeniową. Dodatkową trudnością jest ograniczona możliwość bezpośredniego odczytu amplitud po pomiarze, ponieważ pomiar stanu kwantowego zwraca wynik probabilistyczny, a nie cały zakodowany wektor cech. Z tego względu kodowanie amplitudowe jest teoretycznie atrakcyjne dla danych wysokowymiarowych, ale w zastosowaniach praktycznych wymaga ostrożnej oceny kosztu przygotowania stanu i sposobu odczytu wyniku³⁰.

Szczególną techniką kodowania danych w obwodach kwantowych o małej liczbie kubitów jest ponowne ładowanie danych (ang. data re-uploading). Polega ona na wielokrotnym wprowadzaniu tego samego wektora cech do kolejnych warstw obwodu. W przeciwieństwie do poprzednich podejść, dane wejściowe nie są kodowane jedynie raz, na początku modelu, lecz powracają w kolejnych blokach, przykładowo jako kąty obrotów bramek rotacyjnych, przeplatanych warstwami przetwarzania z parametrami optymalizowanymi klasycznie. Pérez-Salinas i współautorzy pokazują, że taka architektura pozwala częściowo łagodzić ograniczenia wynikające z niewielkiej liczby kubitów w zadaniach klasyfikacyjnych, ponieważ większą ekspresyjność modelu można uzyskać przez zwiększanie liczby warstw i powtórzeń kodowania danych, a nie wyłącznie przez zwiększanie szerokości rejestru kwantowego. Obwód można więc traktować jako sekwencję bloków ponownego ładowania danych oraz bloków przetwarzania, przy czym liczba warstw wpływa na zdolność klasyfikatora do reprezentowania bardziej złożonych granic decyzyjnych. Nie oznacza to jednak, że większa liczba powtórzeń zawsze poprawia wynik: w bardziej

²⁹ M. Schuld, F. Petruccione, *Supervised Learning with Quantum Computers*, op. cit., s. 110-112.

³⁰ Tamże, s. 148-150.

złożonych zadaniach klasyfikacyjnych wzrost liczby warstw może prowadzić do lokalnych minimów i spadku skuteczności klasyfikacji³¹. Pogłębienie obwodu zwiększa ponadto liczbę bramek, koszt optymalizacji oraz ekspozycję modelu na szum kwantowy³². W zastosowaniach do danych finansowych technikę ponownego ładowania danych można zatem traktować jako kompromis między ograniczoną liczbą cech i kubitów a ekspresyjnością modelu oraz praktyczną stabilnością procesu uczenia.

Kodowanie danych nie stanowi jeszcze pełnego modelu kwantowej sieci neuronowej, lecz dopiero pierwszy etap konstrukcji obwodu. Po przygotowaniu stanu wejściowego obwód zawiera zwykle część uczoną, określaną w literaturze jako *ansatz*, zbudowaną (w zależności od przyjętej architektury) z parametryzowanych bramek rotacyjnych, bramek splątujących oraz innych bramek kwantowych³³. W takim ujęciu *feature map* odpowiada za odwzorowanie klasycznego wektora cech do przestrzeni stanów kwantowych, natomiast *ansatz* wprowadza parametry aktualizowane w trakcie procesu uczenia. Dobór tej architektury nie jest neutralny metodologicznie: zbyt prosty obwód może ograniczać zdolność reprezentowania zależności między cechami, natomiast zbyt głęboki zwiększa koszt obliczeń oraz ryzyko trudności optymalizacyjnych. Z tego względu w praktycznych zastosowaniach hybrydowych modeli kwantowego uczenia maszynowego istotne jest łączne uzasadnienie zarówno sposobu kodowania danych, jak i liczby warstw oraz rodzaju bramek tworzących część uczoną modelu. Tym samym wybór metody kodowania danych nie jest jedynie technicznym detałem implementacyjnym, lecz jedną z głównych decyzji projektowych, wpływającą na rozmiar obwodu, koszt uczenia oraz klasę zależności możliwych do reprezentacji przez model³⁴.

³¹ A. Pérez-Salinas, A. Cervera-Lierta, E. Gil-Fuster, J.I. Latorre, *Data re-uploading for a universal quantum classifier*, „Quantum” 2020, vol. 4, art. 226.

³² S. Wang i in., *Noise-induced barren plateaus in variational quantum algorithms*, „Nature Communications” 2021, vol. 12, art. 6961.

³³ S. Sim, P. D. Johnson, A. Aspuru-Guzik, *Expressibility and Entangling Capability of Parameterized Quantum Circuits for Hybrid Quantum-Classical Algorithms*, „Advanced Quantum Technologies” 2019, vol. 2, 1900070.

³⁴ M. Schuld, R. Sweke, J.J. Meyer, *The effect of data encoding on the expressive power of variational quantum-machine-learning models*, op. cit.

Tabela 3.2. Porównanie wybranych metod kodowania danych klasycznych w kwantowym uczeniu maszynowym


Metoda kodowania	Zalety i ograniczenia
<i>basis encoding</i>	Zalety: prosta i intuicyjna reprezentacja danych dyskretnych naturalna dla cech binarnych i kategorii zero-jedynkowych Ograniczenia: słabiej nadaje się do danych ciągłych zwykle wymaga wcześniejszej dyskretyzacji
<i>angle encoding</i>	Zalety: stosunkowo prosta do implementacji na sprzęcie kwantowym dobrze nadaje się do danych rzeczywistych Ograniczenia: wymaga odpowiedniego przeskalowania cech może wymagać osobnej bramki rotacyjnej dla każdej cechy
<i>amplitude encoding</i>	Zalety: zwarta reprezentacja danych wysokowymiarowych umożliwia zakodowanie wektora długości 2^n w stanie n kubitów Ograniczenia: wymaga normalizacji wektora danych wymaga kosztownego przygotowania stanu utrudnia bezpośredni odczyt zakodowanej informacji

Źródło: opracowanie własne na podstawie: M. Schuld, F. Petruccione, *Supervised Learning with Quantum Computers*, Springer, Cham 2018, s. 109-112, 148-150, 186-188.

3.3. Ograniczenia praktyczne kwantowych sieci neuronowych

Analiza praktycznych ograniczeń kwantowych sieci neuronowych jest konieczna, ponieważ obecne modele tej klasy są rozwijane przede wszystkim w realiach zaszumionych urządzeń kwantowych średniej skali (ang. Noisy Intermediate-Scale Quantum, NISQ). Są to urządzenia dysponujące coraz większą liczbą kubitów, lecz nadal ograniczone przez szum, brak pełnej korekcji błędów oraz niewielką głębokość obwodów możliwych do wiarygodnego uruchomienia na rzeczywistym sprzęcie³⁵. Tendencję wzrostu liczby kubitów można zilustrować na przykładzie wybranych procesorów IBM Quantum, przy czym sama liczba kubitów nie przesądza jeszcze o praktycznej użyteczności urządzenia.

Wykres 3.1. Wzrost liczby kubitów w wybranych procesorach IBM Quantum



Źródło: opracowanie własne na podstawie materiałów IBM Quantum dotyczących kolejnych generacji procesorów kwantowych IBM, 2016–2023³⁶.

³⁵ J. Preskill, *Quantum Computing in the NISQ era and beyond*, „Quantum 2” 2018, vol. 2, art. 79.

³⁶ M. Brink, J. Chow, *Bringing agile to quantum hardware*, IBM Quantum Blog, 14.03.2022; IBM, *IBM Unveils 400 Qubit-Plus Quantum Processor and Next-Generation IBM Quantum System Two*, IBM Newsroom, 9.11.2022; J. Gambetta, *The hardware and software for the era of quantum utility is here*, IBM Quantum Blog, 4.12.2023, dostęp: 28.05.2026.

Wskazane ograniczenia mają szczególne znaczenie dla analizy danych finansowych, które mają charakter tabelaryczny, a więc mogą być skutecznie przetwarzane przez modele klasycznego uczenia maszynowego takie jak modele liniowe czy lasy losowe. Z tego względu kwantowych sieci neuronowych nie należy traktować jako technologii automatycznie przewyższającej podejścia klasyczne, lecz jako grupę metod eksperymentalnych, których potencjał powinien być oceniany ostrożnie i w odniesieniu do dobrze dobranych modeli referencyjnych³⁷. Takie ujęcie jest spójne z literaturą dotyczącą wariacyjnych algorytmów kwantowych, w której podkreśla się, że mimo ich znaczenia dla obliczeń w erze NISQ pozostają one ograniczone przez trenowalność, dokładność, podatność na szum oraz efektywność obliczeniową³⁸. W dalszej części podrozdziału zostaną wskazane główne ograniczenia kwantowego uczenia maszynowego.

Jednym z podstawowych ograniczeń praktycznego wykorzystania kwantowych sieci neuronowych jest podatność obwodów kwantowych na szum, wynikający m.in. z niedoskonałości bramek, błędów odczytu oraz procesów dekoherencji. Znaczenie tych zjawisk rośnie wraz z głębokością obwodu, ponieważ każda kolejna warstwa ansatzu i każda dodatkowa bramka wydłużają sekwencję operacji, a tym samym zwiększają prawdopodobieństwo zakłócenia stanu kwantowego. W literaturze podkreśla się, że właśnie szum w bramkach ogranicza rozmiar obwodów, które mogą być wiarygodnie wykonywane na urządzeniach NISQ³⁹. W przypadku hybrydowych kwantowych sieci neuronowych ograniczenie to ma szczególne znaczenie, ponieważ ten sam parametryzowany obwód jest wielokrotnie uruchamiany podczas treningu, predykcji oraz estymacji gradientów. Większa głębokość może zwiększać ekspresyjność modelu, ale jednocześnie pogarszać stabilność treningu i dokładność oraz zwiększać koszt obliczeniowy, dlatego nie powinna być traktowana jako automatyczna poprawa architektury⁴⁰. Co więcej, badania nad algorytmami wariacyjnymi pokazują, że szum może prowadzić do spłaszczania krajobrazu optymalizacji i zanikania gradientów, zwłaszcza gdy głębokość ansatzu rośnie wraz z liczbą kubitów⁴¹. Z tego względu w badaniach empirycznych nad kwantowymi sieciami neuronowymi należy raportować nie tylko jakość predykcji, lecz także liczbę warstw i bramek, liczbę pomiarów,

³⁷ H.-Y. Huang i in., *Power of data in quantum machine learning*, „Nature Communications” 2021, vol. 12, art. 2631.

³⁸ M. Cerezo i in., *Variational quantum algorithms*, op. cit.

³⁹ J. Preskill, *Quantum Computing in the NISQ era and beyond*, op. cit.

⁴⁰ M. Cerezo i in., *Variational quantum algorithms*, op. cit.

⁴¹ S. Wang i in., *Noise-induced barren plateaus in variational quantum algorithms*, op. cit.

sposób estymacji gradientów oraz informację czy wyniki uzyskano na symulatorze idealnym, symulatorze z modelem szumu czy rzeczywistym urządzeniu kwantowym.

Odrębnym ograniczeniem praktycznym jest pomiarowy charakter obliczeń kwantowych. Wynik pojedynczego uruchomienia obwodu kwantowego ma charakter probabilistyczny, dlatego wartości oczekiwane obserwabli, funkcje kosztu oraz gradienty parametrów muszą być zwykle estymowane na podstawie wielu powtórzeń tego samego obwodu. Zwiększa to nakład obliczeniowy treningu, szczególnie w modelach wariacyjnych, w których procedura optymalizacji wymaga wielokrotnego wykonywania obwodów dla różnych wartości parametrów. W konsekwencji praktyczna ocena kwantowych sieci neuronowych powinna uwzględniać nie tylko jakość predykcji, lecz także liczbę uruchomień obwodu potrzebnych do uzyskania stabilnych wyników⁴².

Kolejnym istotnym ograniczeniem praktycznym dla kwantowych sieci neuronowych jest ich trenowalność (ang. trainability) rozumiana jako możliwość skutecznego znalezienia takich parametrów obwodu, które prowadzą do poprawy funkcji kosztu. W przypadku modeli wariacyjnych trenowalność nie zależy wyłącznie od liczby parametrów. Istotne jest również to, jak zachowuje się funkcja kosztu w przestrzeni parametrów oraz czy niewielkie zmiany parametrów prowadzą do zauważalnych zmian w rozkładzie wyników modelu. Jednym ze sposobów formalnego opisu tej zależności jest wykorzystanie macierzy informacji Fishera, która wskazuje, jak silnie predykcje modelu reagują na lokalne zmiany parametrów:

$$(3.8) \quad F_{ij}(\theta) = E_{x,y} \left[\frac{\partial}{\partial \theta_i} \log p_{\theta}(y | x) \frac{\partial}{\partial \theta_j} \log p_{\theta}(y | x) \right].$$

Na tej podstawie można analizować tzw. wymiar efektywny modelu (ang. effective dimension), czyli miarę jego rzeczywistej złożoności reprezentacyjnej, która nie sprowadza się wyłącznie do nominalnej liczby parametrów⁴³. Mały wymiar efektywny może oznaczać ograniczoną zdolność reprezentacji, natomiast zbyt złożona architektura może prowadzić do trudniejszej optymalizacji, zwłaszcza przy niewielkich zbiorach danych. W kontekście kwantowych sieci neuronowych szczególne znaczenie ma więc znalezienie kompromisu między ekspresyjnością ansatzu a jego trenowalnością: model powinien być wystarczająco elastyczny, aby uchwycić zależności w danych, ale nie na tyle złożony, by prowadzić do

⁴² M. Cerezo i in., *Variational quantum algorithms*, op. cit.

⁴³ A. Abbas i in., *The power of quantum neural networks* op. cit.

płaskiego krajobrazu funkcji kosztu i zanikania gradientów⁴⁴. Z tego względu w badaniach empirycznych nad kwantowymi sieciami neuronowymi należy unikać automatycznego zwiększania liczby parametrów i warstw ansatzu, lepszą praktyką jest natomiast porównywanie kilku umiarkowanych wariantów architektury pod względem jakości predykcji, stabilności uczenia oraz kosztu optymalizacji⁴⁵.

Szczególnym przypadkiem problemu trenowalności kwantowych sieci neuronowych jest zjawisko barren plateaus, czyli spłaszczania krajobrazu funkcji kosztu. W takiej sytuacji gradient funkcji straty względem parametrów obwodu staje się bardzo mały, a jego wariancja często maleje wykładniczo wraz ze wzrostem liczby kubitów, przez co klasyczny optymalizator nie otrzymuje użytecznej informacji o kierunku aktualizacji parametrów⁴⁶. Problem ten nie zależy wyłącznie od liczby kubitów i głębokości obwodu, lecz także od samej konstrukcji funkcji kosztu (w literaturze wskazuje się również na sposób inicjalizacji parametrów oraz rodzaj obserwabli)⁴⁷. W konsekwencji zwiększanie liczby parametrów lub głębokości ansatzu nie powinno być traktowane jako automatyczny sposób poprawy modelu. W praktycznej ocenie kwantowych sieci neuronowych równie ważne jak potencjalna ekspresyjność są stabilność oraz nakład obliczeniowy procesu uczenia.

Zastosowania kwantowego uczenia maszynowego w finansach są szerokie i obejmują wiele kategorii zadań, jednak literatura przedstawia ten obszar przede wszystkim jako kierunek eksperymentalny, a nie jako dojrzałą alternatywę dla klasycznych metod uczenia maszynowego. Doosti i współautorzy wskazują, że techniki QML mogą zdobyć zainteresowanie sektora finansowego, nawet jeśli nie wykażą wykładniczego przyspieszenia obliczeń⁴⁸. Badania nad wykorzystaniem hybrydowego kwantowego uczenia maszynowego w ocenie zdolności kredytowej małych i średnich przedsiębiorstw również wskazują na potencjalne korzyści, ale jednocześnie istotne ograniczenia praktyczne, w tym pogorszenie jakości po zwiększeniu liczby kubitów powyżej określonego poziomu (w artykule zasugerowano 12 kubitów) oraz trudności związane z symulatorami i rzeczywistymi

⁴⁴ J.R. McClean i in., *Barren plateaus in quantum neural network training landscapes*, „Nature Communications” 2018, vol. 9, art. 4812.

⁴⁵ Z. Holmes i in., *Connecting ansatz expressibility to gradient magnitudes and barren plateaus*, „PRX Quantum” 2022, vol. 3, art. 010313.

⁴⁶ J.R. McClean i in., *Barren plateaus in quantum neural network training landscapes* op. cit.

⁴⁷ M. Cerezo i in., *Cost function dependent barren plateaus in shallow parametrized quantum circuits*, „Nature Communications” 2021, vol. 12, art. 1791.

⁴⁸ M. Doosti i in., *A brief review of quantum machine learning techniques for financial services*, „Machine Learning: Science and Technology” 2026, s. 1–22

urządzeniami kwantowymi⁴⁹. Wnioski te są spójne z szerszą literaturą dotyczącą badań porównawczych nad modelami kwantowego uczenia maszynowego, która podkreśla, że wyniki modeli kwantowych silnie zależą od projektu eksperymentu, skali problemu, doboru danych i modeli referencyjnych, a klasyczne modele uczenia maszynowego pozostają bardzo konkurencyjne w typowych zadaniach predykcyjnych⁵⁰. Z tego względu kwantowe sieci neuronowe w finansach należy traktować nie jako technologię zapewniającą absolutną przewagę nad klasycznym uczeniem maszynowym, lecz jako grupę modeli eksperymentalnych, których przydatność powinna być oceniana ostrożnie i zawsze w odniesieniu do dobrze dobranych modeli bazowych. Takie ujęcie stanowi punkt wyjścia dla części metodologicznej pracy, w której konieczne jest określenie danych, modeli porównawczych, metryk oceny oraz warunków eksperymentu.

⁴⁹ N. Schetakis i in., *Quantum Machine Learning for Credit Scoring*, „Mathematics” 2024, vol. 12, nr 9, art. 1391.

⁵⁰ J. Bowles, S. Ahmed, M. Schuld, *Better than classical? The subtle art of benchmarking quantum machine learning models*, arXiv:2403.07059 [quant-ph], 2024.